Curso de Probabilidad · Licenciatura en Computación · Quinto semestre

# Proyecto de Probabilidad: modelos de lenguaje de $n$-gramas

Basado en la sección S01 «El lenguaje como distribución de probabilidad» del libro *Modelos de Lenguaje de Gran Escala* (Dr. José G. Marcano)

Noviembre de 2026

**En una línea.** Cada equipo construye, evalúa y compara modelos probabilísticos que predicen el siguiente carácter de un texto en español, y entrega un reporte técnico cuyas cifras se reproducen con su propio código.

## 1. Presentación

El proyecto aplica la sección S01 del libro a un curso de probabilidad para estudiantes de Computación de quinto semestre.

**Pregunta central.** ¿Cuánto mejora la predicción del siguiente carácter al aumentar la memoria del modelo (el orden $n$ de un modelo de $n$-gramas) y a partir de qué orden deja de compensar por falta de datos?

**Objetivos de aprendizaje.** Al terminar, el estudiante podrá:

1. Escribir la probabilidad de una secuencia con la regla de la cadena y simplificarla bajo la hipótesis de Markov.
2. Estimar probabilidades condicionales por máxima verosimilitud (frecuencias relativas) y explicar por qué asignan probabilidad cero a lo no observado.
3. Corregir los ceros con suavizado aditivo y elegir su parámetro con datos de validación, nunca con los de prueba.
4. Medir la calidad predictiva con entropía cruzada, bits por carácter (BPC) y perplejidad (PPL), y comprobar numéricamente la desigualdad de Gibbs.
5. Simular la cadena estimada y comparar su distribución estacionaria con las frecuencias del texto.
6. Cuantificar la incertidumbre de una comparación entre modelos con bootstrap, y redactar un reporte que separe lo verificado de lo ilustrativo.

**Modalidad.** Equipos de 2 o 3 personas; duración sugerida de 4 semanas; Python (recomendado) o R. No se necesita una unidad de procesamiento gráfico (GPU) ni bibliotecas de aprendizaje profundo.

## 2. Conceptos de S01 que usa el proyecto

Todo el proyecto se apoya en ocho ideas de probabilidad de la sección S01; el reporte debe definirlas antes de usarlas, con la notación de la tabla 1. Los números remiten al libro.

Tabla 1: Conceptos de S01 y su definición operativa.

| Concepto | Definición operativa | En el libro |
|---|---|---|
| Vocabulario $\mathcal{V}$ | Conjunto finito de símbolos que el modelo puede predecir (aquí, caracteres); su tamaño es $\lvert\mathcal{V}\rvert$ | Def. 1.1.1 |
| Regla de la cadena | La probabilidad de una secuencia es el producto de las condicionales de cada símbolo dados los anteriores | Prop. 1.1.3 |
| Modelo de $n$-gramas | Cadena de Markov de orden $n-1$: cada carácter depende solo de los $n-1$ anteriores (su *contexto*) | Def. 1.1.6 |
| Máxima verosimilitud (MLE) | Estimar cada condicional por frecuencia relativa: conteo del par (contexto, símbolo) entre conteo del contexto | Prop. 1.1.8 |
| Suavizado aditivo | Sumar $\alpha > 0$ a cada conteo para que nada tenga probabilidad cero | Prop. 1.1.14 |
| Entropía y entropía cruzada | Incertidumbre media de una distribución; costo medio, en bits, de codificar datos de $p$ con un modelo $q$ | §1.1.4, Prop. 1.1.15, Def. 1.1.17, Prop. 1.1.18 |
| BPC y perplejidad | Media de $-\log_2 q$ por carácter evaluado, y 2 elevado a esa media | Def. 1.1.20, Prop. 1.1.42 |
| Bootstrap | Remuestrear con reemplazo unidades independientes para estimar la variabilidad de un estadístico | Def. 1.1.44 |

Las cuatro fórmulas que se programan son las siguientes, donde $x_t$ es el carácter en la posición $t$, $c(\cdot)$ un conteo en el texto de entrenamiento, $h$ un contexto y $N_e$ el número de caracteres evaluados:

$$q(x_{1:T}) = \prod_{t=1}^{T} q\big(x_t \mid x_{t-n+1:t-1}\big), \tag{1}$$

$$\hat{q}_\alpha(y \mid h) = \frac{c(h,y)+\alpha}{c(h)+\alpha\,|\mathcal{V}|}, \qquad \alpha = 0 \text{ es la MLE}, \tag{2}$$

$$\mathrm{BPC} = -\frac{1}{N_e}\sum_{t} \log_2 \hat{q}_\alpha\big(x_t \mid x_{t-n+1:t-1}\big), \qquad \mathrm{PPL} = 2^{\mathrm{BPC}}, \tag{3}$$

$$H(p) = -\sum_i p_i \log_2 p_i \;\le\; H(p,q) = -\sum_i p_i \log_2 q_i \quad \text{(desigualdad de Gibbs, Teo. 1.1.27).} \tag{4}$$

**Nivel del curso.** Se suponen conocidas la probabilidad condicional, la independencia, la esperanza y la ley de los grandes números. La interpretación bayesiana del suavizado (distribución de Dirichlet, Teo. 1.1.12 y Prop. 1.1.13) es **opcional**; quien no la haya visto la trata como una regla de estimación.

## 3. Datos y herramientas

Cada equipo trabaja con un texto en español de al menos 300 000 caracteres, de dominio público o con licencia que permita su uso, aprobado por el profesor en la semana 1.

**Fuente sugerida.** Una obra en español de Project Gutenberg (`https://www.gutenberg.org`). Se elimina el preámbulo y la licencia del archivo, y se registran en el reporte el título, el autor, la URL y la fecha de descarga. Dos equipos no pueden usar la misma obra.

**Normalización obligatoria** (documentada en el reporte):

1. Pasar a minúsculas y reemplazar cualquier carácter fuera del alfabeto elegido por un único símbolo especial, por ejemplo «#»; el alfabeto elegido (letras con tildes, ñ, dígitos, signos) se declara en el reporte.
2. Colapsar los espacios y saltos de línea repetidos en un solo espacio.
3. Fijar el vocabulario $\mathcal{V}$ a partir del texto de entrenamiento y reportar $|\mathcal{V}|$ (típicamente entre 30 y 45 símbolos).

**Partición.** El texto se divide en tres bloques **contiguos**: 80 % entrenamiento, 10 % validación y 10 % prueba, en ese orden. No se mezclan caracteres ni oraciones al azar: un texto tiene dependencia entre posiciones vecinas, y mezclar filtraría información del entrenamiento a la evaluación. El bloque de prueba se usa **una sola vez**, al final.

**Herramientas permitidas.** Python 3 con la biblioteca estándar, NumPy, pandas y Matplotlib, o R base con ggplot2. Los conteos, el suavizado, las métricas, la simulación y el bootstrap los programa el equipo.

**No permitido.** Bibliotecas que ya implementen modelos de lenguaje o $n$-gramas (por ejemplo, el módulo `lm` de NLTK o KenLM), redes neuronales y modelos de lenguaje de terceros para producir resultados. El uso de asistentes de inteligencia artificial para redactar o depurar se permite solo si se declara (sección 7).

**Prueba de cordura obligatoria.** Antes de usar el corpus, el código debe reproducir las cifras de la tabla 2 con el texto de juguete *abracadabra* (cifras verificadas con Python).

Tabla 2: Valores esperados para el texto *abracadabra*.

| Magnitud | Valor esperado |
|---|---|
| Conteos de unigramas | a 5, b 2, r 2, c 1, d 1 |
| Entropía de las frecuencias de unigramas | 2.0404 bits |
| $\hat{q}(\text{b} \mid \text{a})$ por MLE (bigramas) | 0.5 |
| $\hat{q}_\alpha(\text{b} \mid \text{a})$ con $\alpha = 1$ y $\lvert\mathcal{V}\rvert = 5$ | $1/3 \approx 0.3333$ |
| BPC del bigrama MLE sobre sus 10 transiciones | 0.6 bits |
| PPL correspondiente | 1.5157 |

## 4. Tareas del proyecto

El proyecto tiene seis fases obligatorias y una opcional; cada fase produce al menos una tabla (T) o una figura (F) que va al reporte. Las preguntas en cursiva deben responderse explícitamente en la sección de discusión del reporte.

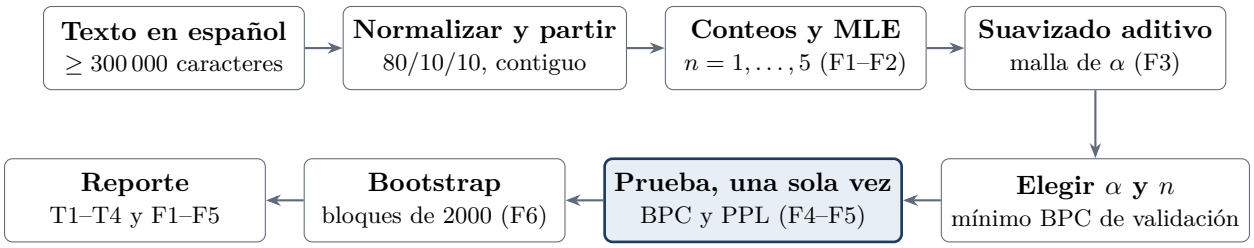



Figura 1: Flujo del proyecto. Todas las decisiones ($\alpha$ y el orden $n$) se toman con validación; el bloque de prueba solo se usa al final. La simulación de la Fase 5 usa el modelo de bigramas ya suavizado. (F$k$ = Fase $k$.)

### Fase 1. Explorar el corpus

- Contar caracteres en cada partición y la frecuencia de cada símbolo de $\mathcal{V}$ en entrenamiento.
- Calcular la entropía de las frecuencias de unigramas, $H(\hat{p})$, y compararla con $\log_2 |\mathcal{V}|$, su máximo posible (Prop. 1.1.15).
- **T1:** tamaño de cada partición y $|\mathcal{V}|$. **F1:** frecuencias de los símbolos, ordenadas de mayor a menor.
- *¿Qué tan lejos está el texto de ser «al azar» sobre su alfabeto? Interprete la diferencia en bits.*

### Fase 2. Estimar por máxima verosimilitud

- Programar los conteos de contextos y de pares (contexto, símbolo) para $n = 1, 2, 3, 4, 5$, y las condicionales MLE.
- Comprobar que cada condicional suma 1 sobre $\mathcal{V}$ (tolerancia $10^{-12}$).
- Calcular la log-verosimilitud del entrenamiento con la MLE y con dos perturbaciones (mover 0.01 de probabilidad entre dos símbolos de un contexto frecuente): la MLE debe dar la mayor (Prop. 1.1.8).
- Para las primeras $n-1$ posiciones de validación y de prueba, tomar como contexto el final de la partición anterior. Medir en validación la proporción de caracteres a los que el modelo MLE asigna probabilidad cero, para cada $n$.
- **T2:** contextos distintos observados y proporción de ceros en validación, por $n$.
- *¿Por qué el BPC de la MLE en validación es infinito en cuanto aparece un cero? ¿Por qué crece la proporción de ceros con $n$?*

### Fase 3. Suavizar y elegir $\alpha$ con validación

- Implementar el suavizado aditivo (2) para $\alpha \in \{0.001, 0.003, 0.01, 0.03, 0.1, 0.3, 1\}$.
- Para cada $n$, elegir el $\alpha$ que minimiza el BPC de **validación**.
- **F2:** BPC de validación contra $\alpha$ (eje horizontal logarítmico), una curva por $n$.
- *¿Por qué el $\alpha$ óptimo cambia con $n$? ¿Qué ocurre con $\alpha = 1$ en contextos que aparecen pocas veces?*
- Opcional: mostrar que, con dos símbolos y distribución previa Beta$(\alpha, \alpha)$, la media predictiva posterior coincide con la fórmula (2) (caso particular de la Prop. 1.1.14).

### Fase 4. Evaluar en prueba y comprobar la teoría

- Elegir el mejor $n$ por el BPC de validación. Con el $\alpha$ elegido para cada $n$, calcular **una sola vez** el BPC y la PPL de prueba, y el BPC de entrenamiento.
- Comprobar la desigualdad de Gibbs (4) con el modelo de unigramas: $H(\hat{p}_{\text{prueba}}) \leq H(\hat{p}_{\text{prueba}}, \hat{q})$, y calcular la divergencia de Kullback–Leibler (KL) como diferencia de ambas (Def. 1.1.17).
- Graficar el promedio acumulado de $-\log_2 \hat{q}$ a lo largo del texto de prueba: debe estabilizarse, como predice la ley de los grandes números.
- **T3:** BPC de entrenamiento, BPC y PPL de prueba y $\alpha$ elegido, por $n$. **F3:** BPC de entrenamiento y de prueba contra $n$ en la misma gráfica. **F4:** promedio acumulado.
- *¿Qué $n$ elige la validación y confirma la prueba ese orden? ¿Por qué el BPC de entrenamiento sigue bajando cuando el de prueba ya no?*

### Fase 5. Simular la cadena y su distribución estacionaria

- Con el modelo de bigramas suavizado, construir la matriz de transición $P$ de tamaño $|\mathcal{V}| \times |\mathcal{V}|$ y comprobar que sus filas suman 1 y sus entradas son positivas.
- Calcular su distribución estacionaria $\pi$ por iteración de potencias ($\pi_0 P^t$) hasta que la norma $\ell_1$ entre iteraciones sea menor que $10^{-10}$ (Teo. 1.1.40), y compararla con las frecuencias de unigramas.
- Generar con semilla fija 3 muestras de 300 caracteres con los modelos $n = 2$, 3 y 5, partiendo del mismo contexto inicial.
- **F5:** $\pi$ frente a las frecuencias de unigramas. **Anexo:** las muestras generadas, con la semilla.
- *¿Por qué $\pi$ se parece a las frecuencias del texto? ¿Qué propiedades del español capturan las muestras y cuáles no?*

### Fase 6. Cuantificar la incertidumbre

- Dividir el texto de prueba en bloques contiguos de 2000 caracteres y calcular, en cada bloque $j$, la diferencia $\Delta_j$ entre el BPC de dos modelos (el mejor $n$ frente a $n-1$).
- Construir un intervalo bootstrap percentil del 95 % para la media de las $\Delta_j$ con 10 000 remuestras y semilla fija (Def. 1.1.44).
- **T4:** media de las $\Delta_j$, intervalo y número de bloques.
- *¿El intervalo excluye el cero? ¿Por qué se remuestrean bloques y no caracteres individuales?*

### Fase 7 (opcional, hasta 10 puntos extra). Tokenización por pares de bytes

- Implementar 200 fusiones de codificación por pares de bytes (Byte Pair Encoding, BPE; Def. 1.1.2) y entrenar un bigrama de tokens.
- Reportar su BPC **por carácter** (bits totales del texto de prueba entre su número de caracteres) para compararlo de forma justa con la Fase 4.

## 5. Formato del reporte entregable

El entregable es un reporte técnico en PDF de 10 a 14 páginas (sin contar anexos), más el código que reproduce cada cifra; se califica tanto el contenido como el cumplimiento de este formato.

### 5.1 Estructura obligatoria

Tabla 3: Estructura del reporte.

| Sección | Qué debe contener | Extensión |
|---|---|---|
| Portada | Título, curso, número de equipo, integrantes con cédula, profesor, fecha | 1 pág. |
| Resumen | Pregunta, datos, método, resultado principal con su número (mejor $n$ y su BPC de prueba) | $\leq$ 200 palabras |
| 1. Introducción | Problema de predecir el siguiente carácter, pregunta central, organización del reporte | ½–1 pág. |
| 2. Marco probabilístico | Definiciones de la sección 2 de este enunciado con notación propia y consistente; deducción de la MLE (puede ir al Anexo A) | 2–3 pág. |
| 3. Datos | Obra, URL, fecha de descarga, licencia, normalización, $\mathcal{V}$ y partición; T1 y F1 | 1 pág. |
| 4. Métodos | Modelos, suavizado, selección de $\alpha$, métricas, simulación y bootstrap, con suficiente detalle para repetirlos | 1–2 pág. |
| 5. Resultados | T2–T4 y F2–F5, cada una citada y comentada en el texto | 3–4 pág. |
| 6. Verificaciones | Prueba de cordura con *abracadabra*, sumas de condicionales, desigualdad de Gibbs, convergencia de $\pi$: qué se comprobó y con qué tolerancia | ½–1 pág. |
| 7. Discusión y limitaciones | Respuestas a las preguntas en cursiva de la sección 4; qué no permiten concluir los datos | 1–2 pág. |
| 8. Conclusiones | Respuesta a la pregunta central en 3 a 5 oraciones | ½ pág. |
| Referencias | Libro del curso y toda fuente consultada, con formato uniforme | — |
| Anexo A | Deducción de la MLE con multiplicador de Lagrange y, si se hizo, la opción bayesiana | libre |
| Anexo B | Reproducibilidad: versiones de software, semillas, comandos y tiempo de ejecución | libre |
| Anexo C | Muestras generadas (Fase 5) y declaración de uso de IA | libre |

### 5.2 Presentación

- Tamaño carta, márgenes de 2.5 cm, letra de 11 pt, interlineado 1.15, páginas numeradas.
- Se recomienda LaTeX; se acepta un procesador de texto si las fórmulas usan su editor de ecuaciones. Las fórmulas importantes van numeradas y centradas.
- Punto como separador decimal y 4 cifras significativas para BPC y PPL (por ejemplo, 2.153 bits).
- Toda tabla lleva título arriba y toda figura lleva leyenda abajo; ambas se numeran, se citan en el texto antes de aparecer e indican unidades (bits, caracteres).
- Las figuras se generan con código, con ejes rotulados y legibles al imprimir en blanco y negro; no se aceptan capturas de pantalla.
- Todo número del reporte sale de una ejecución del código entregado. Un número construido a mano para explicar algo se rotula **ilustrativo**.
- No se pega código en el cuerpo del reporte; solo fragmentos de 15 líneas o menos cuando aclaran un paso.

### 5.3 Archivos que se entregan

Un único archivo comprimido llamado `P1_EquipoNN_Apellido1_Apellido2.zip` (NN = número de equipo, dos dígitos), con esta estructura:

```
P1_EquipoNN_Apellido1_Apellido2/
|-- reporte.pdf
|-- README.md            # cómo ejecutar todo, en el orden correcto
|-- requirements.txt     # o sessionInfo.txt si se usó R
|-- datos/
|   `-- FUENTE.md        # título, URL y fecha de descarga (no subir el texto)
|-- codigo/
|   |-- preparar.py      # lectura, normalización y partición
|   |-- modelos.py       # conteos, MLE, suavizado, métricas
|   |-- experimentos.py  # fases 1 a 6; escribe resultados/
|   `-- pruebas.py       # prueba de cordura y comprobaciones
`-- resultados/          # tablas (.csv) y figuras (.pdf o .png) del reporte
```

**Criterio de reproducibilidad:** en un equipo limpio, ejecutar los comandos del `README.md` debe regenerar todas las tablas y figuras del reporte en menos de 10 minutos.

### 5.4 Lista de comprobación antes de entregar

☐ El resumen da el mejor $n$ y su BPC de prueba con su intervalo bootstrap.
☐ Cada símbolo y término está definido antes de su primer uso.
☐ El bloque de prueba se usó una sola vez y el reporte lo dice.
☐ `pruebas.py` reproduce las cifras de *abracadabra* y pasa sin errores.
☐ Las tablas T1–T4 y las figuras F1–F5 están numeradas, citadas y comentadas.
☐ Cada pregunta en cursiva de la sección 4 tiene respuesta en la sección 7 del reporte.
☐ Las referencias incluyen la obra usada y el libro del curso.
☐ El nombre del archivo y la estructura de carpetas siguen la sección 5.

## 6. Criterios de evaluación

El proyecto vale 100 puntos, más hasta 10 de la Fase 7; un reporte sin código que reproduzca sus cifras obtiene como máximo 50.

Tabla 4: Rúbrica de evaluación.

| Criterio | Pts. | Excelente (90–100 %) | Suficiente (60–89 %) | Insuficiente ($< 60$ %) |
|---|---|---|---|---|
| Marco probabilístico y deducciones | 20 | Definiciones correctas antes de su uso; MLE deducida paso a paso; notación consistente | Definiciones correctas con omisiones menores o pasos sin justificar | Conceptos confundidos (p. ej., entropía y entropía cruzada) o fórmulas sin explicar |
| Implementación y verificaciones | 20 | Prueba de cordura, sumas, Gibbs y convergencia de $\pi$ comprobadas con tolerancias declaradas | Comprobaciones parciales | Sin comprobaciones, o cifras que no coinciden con *abracadabra* |
| Resultados y análisis | 25 | T1–T4 y F1–F5 completas; preguntas en cursiva respondidas con argumentos probabilísticos | Resultados completos con análisis superficial | Resultados incompletos o sin interpretar |
| Incertidumbre y protocolo | 10 | Prueba usada una vez; bootstrap por bloques bien justificado; conclusión acorde al intervalo | Bootstrap correcto con justificación débil | $\alpha$ o $n$ elegidos con prueba, o conclusiones sin incertidumbre |
| Reproducibilidad | 10 | `README.md` y semillas regeneran todo en menos de 10 minutos | Se regenera con ajustes menores | No se puede ejecutar |
| Redacción y formato | 15 | Cumple la sección 5 completa; texto claro y preciso | Incumplimientos menores de formato | Fuera de extensión, o tablas y figuras sin numerar ni citar |
| Fase 7 (opcional) | +10 | BPE correcto y comparación justa por carácter | Implementación con comparación discutible | — |

**Penalizaciones.** $-10$ puntos por día de retraso, hasta un máximo de dos días. Usar el bloque de prueba para elegir $\alpha$ o $n$ anula el criterio de incertidumbre y protocolo (10 puntos).

## 7. Calendario, entrega e integridad

El proyecto dura cuatro semanas con dos revisiones breves; el profesor fija las fechas al publicar el enunciado.

Tabla 5: Calendario sugerido.

| Semana | Trabajo | Se entrega |
|---|---|---|
| 1 | Elegir la obra, normalizar, particionar; Fase 1; prueba de cordura | Obra elegida (para aprobación) y salida de `pruebas.py` |
| 2 | Fases 2 y 3 | Revisión 1: T2 y F2 en borrador (10 minutos de consulta por equipo) |
| 3 | Fases 4, 5 y 6 | Revisión 2: T3, T4 y F3–F5 en borrador |
| 4 | Redacción del reporte y revisión cruzada de reproducibilidad | Archivo final (sección 5) |

**Trabajo en equipo.** El reporte incluye al final una tabla breve con la contribución de cada integrante. Cualquier integrante debe poder explicar cualquier parte del código y del reporte en una defensa oral de 10 minutos, que el profesor puede solicitar.

**Integridad académica.** Se permite consultar el libro, la documentación de Python o R y otras fuentes, citándolas. El uso de asistentes de inteligencia artificial se declara en el Anexo C del reporte: herramienta, para qué se usó y qué se verificó por cuenta propia. Copiar código o texto de otro equipo, o presentar cifras que el código entregado no produce, anula el proyecto.

## Referencias


- Marcano, J. G. *Modelos de Lenguaje de Gran Escala: fundamentos matemáticos, arquitecturas y aplicaciones*, sección S01 «El lenguaje como distribución de probabilidad» (§§1.1.2–1.1.5 y Complementos de S01). Edición v0.9 del curso.
- Shannon, C. E. (1948). A Mathematical Theory of Communication. *Bell System Technical Journal*, 27, 379–423 y 623–656. Origen de la entropía; incluye aproximaciones al inglés generadas con $n$-gramas de letras.
- Cover, T. M. y Thomas, J. A. (2006). *Elements of Information Theory*, 2.ª ed. Wiley. Entropía, entropía cruzada y divergencia KL.
- Efron, B. y Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall. Intervalos percentiles.
- Project Gutenberg: `https://www.gutenberg.org`. Fuente sugerida de textos en español de dominio público.