Informe piloto: bigramas sobre bitácoras sintéticas

Laboratorio S01 · ejemplo ejecutado en Python

17 de octubre de 2026

Resumen

Se demuestra el protocolo mínimo para comparar modelos probabilísticos con métricas homogéneas y un informe reproducible. Los documentos se han fabricado para la clase: la experiencia no constituye evidencia de campo.

1. Pregunta y datos

Se ajustaron dos bigramas de caracteres sobre 8 textos generales y 8 textos técnicos, respectivamente. Se evaluaron en 6 textos técnicos distintos, igualmente sintéticos. No se descargaron corpus ni se ejecutaron modelos LLM.

2. Método

Vocabulario común fijado con entrenamiento, minúsculas, recorte de espacios extremos, suavizado aditivo $\alpha = 1$, BOS y EOS declarados. La métrica es $\mathrm{BPC}(z) = -\log_2 \widehat{P}(z, \mathrm{EOS})/|z|$, contando puntos de código Unicode sin EOS en el denominador.

3. Resultados reproducidos

Documento	Caracteres	BPC general	BPC técnico	Diferencia
E01	27	4.167	3.609	-0.559
E02	34	4.269	3.448	-0.821
E03	32	3.900	3.533	-0.367
E04	37	4.188	3.665	-0.523
E05	36	4.176	3.558	-0.619
E06	31	3.840	3.487	-0.353

Diferencia media (técnico menos general): $-0{,}54024842$ bits/carácter. El intervalo percentil al 95 % fue $[-0{,}66770598, -0{,}42038147]$, obtenido por enumerar $6^6 = 46656$ remuestras de documentos con reemplazo y conservar el pareamiento.

4. Microexperimento BPE de tokenizacion (IC10)

Ajustamos dos tokenizadores BPE didacticos, uno en texto general y otro tecnico, con 20 fusiones cada uno; las reglas se aprendieron *solo* de entrenamiento y se aplicaron a los mismos seis documentos reservados:

Tokenizador	Tokens	Tokens/palabra
BPE general	148	4.228571
BPE tecnico	127	3.628571

Son 35 palabras, diferencia total -21 tokens. Es un resultado de **longitud tokenizada**, no de prediccion ni de un LLM.

5. Interpretación y límites

La comparación favorece al modelo técnico para *estos seis ejemplos inventados*. No estima efectos poblacionales; el intervalo tampoco controla sesgos de selección o de redacción. No se han comparado tokenizadores modernos. En un estudio real se exigen licencia de corpus, particiones blindadas, baselines, varias semillas y validación externa.

6. Vínculo con investigación y objetivo Q1

El problema IC10 plantea estudiar la penalización de tokenización en textos técnicos en español. La experiencia de esta sesión solo enseña a medir y documentar. Un artículo candidato a una revista Q1 exige contribución novedosa, literatura crítica, evidencia sobre datos reales, robustez y reproducibilidad. La obligación de S01 es identificar dos áreas de interés; la selección formal del problema ocurre en S05.