Taller 01: de los tokens al reporte

Cinco actividades obligatorias · R/Python · investigación desde S01

Taller autónomo con reporte técnico breve

Finalidad y entrega

Demostrar, con cálculos y archivos regenerables, cómo las decisiones de representación afectan a un pequeño modelo de lenguaje. Entregar un **reporte de 2–3 páginas** (objetivo, datos, métodos, resultados, incertidumbre, limitaciones y relación con IC10), más scripts y CSV. **Todo es trabajo autónomo**; no se presuponen las horas del laboratorio dentro de la clase presencial. En S01 se conservan como hito de investigación **dos áreas de interés**, cada una con un párrafo.

Actividad 1 [Representación]: una frase, cuatro objetos

Segmente "el gato mira al perro" en palabras y caracteres; construya unigramas, bigramas y trigramas; contraste bolsa de palabras con secuencia y escriba el vector one-hot del token `gato`. Repita el primer paso con una frase técnica. *Autoverificación*: cinco palabras, cuatro pares, tres trigramas en la primera oración.

Actividad 2 [Cálculo]: del conteo a la predicción

Con `abacabbacb` construya la matriz de transiciones, derive el estimador MLE e introduzca $\alpha = 1$. Para `abca`, calcule la probabilidad de transición y la conjunta con $p(X_1 = a) = 1/3$. *Autoverificación*: $P(b \mid a) = 3/7$; probabilidad conjunta $1/105$.

Actividad 3 [Demostración]: medir lo que se predice

Demuestre la identidad entre entropía cruzada y KL con las condiciones de soporte; calcule KL de $(1/2, 1/4, 1/4)$ respecto de $(1/4, 1/2, 1/4)$. Para las probabilidades observadas $(1/2, 1/4, 1/8, 1/2)$, calcule PPL. Compare dos tokenizadores con $(T_A, \mathrm{PPL}_A) = (100, 3.2)$ y $(T_B, \mathrm{PPL}_B) = (30, 25)$ sobre un mismo texto de 100 caracteres, indicando qué supuestos permiten interpretar el BPC. *Autoverificación*: KL $= 0.25$ bits y PPL $= 2^{7/4}$.

Actividad 4 [Algoritmos]: BPE, R y Python

Ejecute seis fusiones BPE sobre la tabla *casa, casas, cosa, cosas, caso* con las frecuencias y reglas indicadas en la sección 1.1.2 del libro. Ejecute después:

```
python codigo/s01.py
python codigo/experimento_s01.py
python codigo/ic10_tokenizadores.py
Rscript codigo/s01.R
Rscript codigo/experimento_s01.R
Rscript codigo/ic10_tokenizadores.R
```

Compruebe las sumas de las filas, las longitudes BPE y las seis filas pareadas del CSV. Compare también, sobre las mismas seis frases de prueba, el BPE general con el tecnico mediante 20 fusiones en ambos; produzca `resultados_ic10_tokenizacion.csv` y explique las diferencias. Si no tiene R, indique **PENDIENTE** en el reporte, sin inventar que los números se reprodujeron en ambos lenguajes.

Actividad 5 [Aplicación e investigación]: entregar evidencia

Use `experimentos/corpus_didactico.csv` para reconstruir `experimentos/resultados_python.csv`; complete la **plantilla de reporte** en `reportes/reporte_s01.tex`. Incluya la tabla BPE con tokens por palabra y distinga la comparación de tokenizadores de la comparación de predictores por caracteres. Interprete la diferencia media de BPC y el intervalo bootstrap por *documento*, explicando por qué ni el tamaño de muestra ni el origen del corpus permiten inferencia para textos industriales reales. Proponga una versión de IC10 que sí sea falsable con documentos y comparaciones externas. Finalmente, formule dos áreas de interés, con un párrafo justificado por cada una.

Lista de control antes de entregar

1. Los datos no se mezclan entre ajuste y prueba; se identifica cada unidad de observación.
2. Se reportan todas las probabilidades de la cadena, incluido EOS, y se cuenta explícitamente la unidad del denominador BPC.
3. Cada resultado se etiqueta como *calculado*, *ejecutado con datos sintéticos* o *pendiente de validación empírica*.
4. Se entregan código, CSV, versión de lenguaje, interpretación, limitaciones y dos áreas de interés.

Extensiones opcionales, fuera del núcleo S01

Calcule intervalo de confianza mediante bootstrap jerárquico con varios documentos por fuente; incorpore una evaluación BPC de modelos probabilisticos sobre tokens BPE con distribuciones comparables; compare vocabularios fijados por entrenamiento con distintos tamaños; pruebe suavizado $\alpha \in \{1/2, 1, 2\}$ exclusivamente en validación; diseñe una réplica externa para dos dominios técnicos con control de licencias.